

Prédiction du comportement mécanique d'une poutre en porte-à-faux par modèle de substitution (Surrogate Model)

Une approche combinant simulation par éléments finis et Machine Learning

Junior Teddy DADJEU TEMGOUA

6 septembre 2026

Résumé

Le dimensionnement mécanique de pièces structurales repose classiquement sur des simulations par éléments finis (FEM), coûteuses en temps de calcul lorsqu'il faut explorer un grand nombre de variantes géométriques. Ce projet développe et valide un modèle de substitution (surrogate model) par apprentissage automatique, capable de prédire la flèche et la contrainte maximales d'une poutre en porte-à-faux à partir de sa géométrie, en remplacement d'une simulation FEM. Un solveur éléments finis a été développé et validé analytiquement, un jeu de données de simulations a été généré, et plusieurs modèles de régression ont été comparés. Le meilleur modèle, exploitant la structure en loi de puissance du problème via une transformation logarithmique, atteint une précision parfaite ($R^2 = 1.0$) sur ce cas linéaire. Le modèle a ensuite été utilisé pour résoudre un problème d'optimisation géométrique sous contraintes, et intégré dans une application web interactive.

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	Objectifs	2
2	Méthodologie	2
2.1	Cas d'étude	2
2.2	Solveur éléments finis	2
2.3	Génération du jeu de données	3
2.4	Modèles de Machine Learning	3
3	Résultats	3
3.1	Performance des modèles	3
3.2	Validation visuelle	3
3.3	Temps de calcul	3
3.4	Optimisation géométrique	4
4	Discussion et limites	4
5	Conclusion	5
6	Perspectives	5

1 Introduction

1.1 Contexte

La conception de pièces mécaniques structurales — longerons de châssis automobile, éléments porteurs en aéronautique, supports industriels — nécessite classiquement de recourir à la simulation par éléments finis (FEM) pour évaluer leur comportement sous charge : déformation, contraintes internes, risque de rupture. Ces simulations, bien que précises, deviennent coûteuses en temps de calcul dès lors qu’il faut explorer un grand nombre de configurations géométriques, que ce soit dans une démarche d’optimisation, une étude de sensibilité, ou une phase de conception itérative où l’ingénieur souhaite tester rapidement plusieurs variantes.

Cette contrainte a motivé, ces dernières années, le développement des *modèles de substitution* (*surrogate models*), des modèles d’apprentissage automatique entraînés sur un ensemble de simulations FEM, capables ensuite de prédire le comportement mécanique d’une nouvelle configuration en un temps quasi instantané, sans relancer de calcul complet. Cette approche s’inscrit dans une tendance plus large de couplage entre modélisation physique et intelligence artificielle, aujourd’hui utilisée dans des domaines aussi variés que l’aéronautique, l’énergie ou le biomédical, pour accélérer les cycles de conception et permettre des optimisations qui seraient autrement trop coûteuses en temps de calcul direct.

Ce projet propose une mise en œuvre complète de cette démarche sur un cas d’étude simple mais représentatif : une poutre en porte-à-faux, pour laquelle on dispose d’une solution analytique de référence, permettant de valider rigoureusement chaque étape de la chaîne de traitement, de la simulation à la prédiction par apprentissage automatique.

1.2 Objectifs

Ce projet poursuit trois objectifs :

- Développer et valider un solveur éléments finis pour une poutre en flexion ;
- Entraîner un modèle de substitution prédisant la flèche et la contrainte maximales à partir de la géométrie ;
- Démontrer l’utilité du modèle pour l’optimisation de design, via une application interactive.

2 Méthodologie

2.1 Cas d’étude

On considère une poutre en porte-à-faux (encastree-libre), de section rectangulaire constante ($b \times h$), de longueur L , soumise à une charge ponctuelle verticale F appliquée à son extrémité libre (matériau : acier, $E = 210$ GPa).

2.2 Solveur éléments finis

Le solveur repose sur la théorie des poutres d’Euler-Bernoulli, discrétisée en n éléments à 2 degrés de liberté par nœud (déplacement vertical v , rotation θ). La matrice de rigidité élémentaire, la procédure d’assemblage et l’application des conditions aux limites (encastrement) suivent la formulation classique des éléments finis de poutre.

Le solveur a été validé par comparaison aux formules analytiques de référence :

$$\delta_{max} = \frac{FL^3}{3EI} \tag{1}$$

$$\sigma_{max} = \frac{M_{max} h}{2I}, \quad M_{max} = FL \tag{2}$$

avec $I = bh^3/12$ le moment quadratique de la section. L'écart entre le solveur FEM (10 éléments) et la solution analytique est inférieur à 0.1%, validant l'implémentation.

2.3 Génération du jeu de données

Un premier tirage uniforme classique des paramètres géométriques a produit un jeu de données mal réparti : la sensibilité en $1/h^3$ de la flèche à la hauteur h sur-représentait les configurations peu sensibles et sous-représentait les cas extrêmes. Un tirage *log-uniforme* a été adopté pour obtenir une couverture équilibrée de l'espace des paramètres à toutes les échelles. Les configurations produisant une flèche supérieure à 10% de la longueur de la poutre ont été écartées, ce régime sortant du domaine de validité de la théorie linéaire des poutres.

2.4 Modèles de Machine Learning

Deux familles de modèles ont été comparées : une régression linéaire et une forêt aléatoire (Random Forest), chacune entraînée sur les données brutes puis sur une transformation logarithmique des entrées *et* des sorties. Cette seconde approche exploite le fait que la relation physique du problème est une loi de puissance ($\delta \propto FL^3b^{-1}h^{-3}$), donc linéaire en échelle log-log.

3 Résultats

3.1 Performance des modèles

Configuration	R^2 flèche	R^2 contrainte
Random Forest, échantillonnage uniforme	0.66	0.75
Random Forest, log(sorties) uniquement	0.55	0.69
Random Forest, log-log, échant. log-uniforme	0.85	0.92
Régression linéaire, log-log	1.00	1.00

TABLE 1 – Comparaison des performances selon la méthode d'échantillonnage et de transformation des variables.

La régression linéaire en log-log atteint une précision parfaite, confirmant que le problème est exactement une loi de puissance sur le domaine de validité linéaire considéré. Ce résultat illustre l'intérêt d'exploiter la structure physique connue d'un problème plutôt que de recourir systématiquement à un modèle non-linéaire plus complexe.

3.2 Validation visuelle

3.3 Temps de calcul

Le solveur FEM développé, appliqué à ce cas 1D linéaire à 10 éléments, s'exécute en environ 0.12 ms par appel, contre environ 0.52 ms pour une prédiction du modèle ML. Contrairement à l'intuition habituelle sur les surrogate models, le modèle ML est ici *plus lent* que le calcul direct.

Ce résultat s'explique par la simplicité volontaire du cas d'étude : un système linéaire à 22 degrés de liberté se résout quasi instantanément, tandis qu'un appel à un modèle scikit-learn comporte un coût fixe (conversion de données, appels internes) qui domine ici le temps total. L'intérêt d'un surrogate model se manifeste pour des simulations de référence coûteuses (maillages fins, non-linéarités géométriques ou matérielles, contact) — un cas qui dépasse le cadre de ce projet mais qui constitue une perspective naturelle (voir Section 5).




FIGURE 1 – Comparaison des prédictions du modèle ML aux valeurs calculées par le solveur FEM, pour la flèche (gauche) et la contrainte (droite).

3.4 Optimisation géométrique

Le modèle a été utilisé pour résoudre un problème d'optimisation sous contrainte : minimiser le volume de matière $V = Lbh$ sous contraintes de flèche maximale admissible et de contrainte admissible. Pour $L = 1.5$ m, $F = 2000$ N, une flèche admissible de 5 mm et un coefficient de sécurité de 1.5 sur la limite élastique de l'acier, la géométrie optimale obtenue est $b = 20.0$ mm, $h = 108.7$ mm, avec une flèche de 5.00 mm (contrainte active) et une contrainte de 76.1 MPa, très en-deçà de la limite admissible (166.7 MPa). Ce résultat illustre que le dimensionnement est ici piloté par la rigidité de la pièce plutôt que par sa résistance à la rupture.

4 Discussion et limites

Les résultats obtenus démontrent la faisabilité complète d'une chaîne de traitement allant de la simulation physique à un modèle de substitution exploitable pour l'optimisation, mais plusieurs limites méritent d'être discutées.

Simplicité du cas d'étude. Le choix d'une poutre 1D en régime linéaire a été délibéré, pour permettre une validation analytique rigoureuse de chaque étape. Cette simplicité a toutefois une conséquence directe : la relation entre géométrie et comportement mécanique est une loi de puissance exacte, ce qui explique la précision parfaite obtenue par une simple régression linéaire en log-log. Ce résultat ne se généralise pas à des géométries plus complexes (profilés non standards, structures 2D/3D, assemblages), pour lesquelles la relation entrée-sortie n'admet pas de forme analytique simple et où un modèle non-linéaire (Random Forest, réseau de neurones) serait nécessaire et pertinent.

Domaine de validité restreint. Le modèle n'a été entraîné et validé que sur le domaine de paramètres défini dans le cahier des charges, et sur des configurations où la flèche reste inférieure à 10% de la longueur de la poutre (domaine de validité de la théorie linéaire d'Euler-Bernoulli). Toute extrapolation en dehors de ce domaine n'est pas garantie et nécessiterait une nouvelle campagne de simulations.

Hypothèses simplificatrices du modèle physique. Le solveur ne prend en compte ni les effets dynamiques (vibrations, chargements variables dans le temps), ni la fatigue, ni les non-linéarités géométriques ou matérielles (plasticité), ni les concentrations de contraintes locales (trous, congés de raccordement) qui seraient pourtant déterminantes sur une pièce réelle comme un longeron de châssis.

Non-démonstration du gain de temps de calcul. Comme discuté en Section 3.4, le modèle ML s’est révélé plus lent que le calcul FEM direct sur ce cas volontairement simple. L’intérêt réel d’un surrogate model — accélérer des calculs coûteux — n’a donc pas pu être quantifié empiriquement dans ce projet, et reste à démontrer sur un cas de simulation plus lourd (maillage 2D/3D fin, comportement non-linéaire).

Matériau unique. Le modèle a été entraîné avec les propriétés de l’acier fixées ($E = 210$ GPa), sans faire varier le matériau. L’intégration du module de Young comme variable d’entrée supplémentaire permettrait d’élargir le champ d’application du modèle sans complexité méthodologique majeure.

5 Conclusion

Ce projet a permis de mettre en œuvre une chaîne complète de modélisation mécanique augmentée par l’apprentissage automatique : développement et validation analytique d’un solveur éléments finis, génération raisonnée d’un jeu de données de simulation, entraînement et comparaison de plusieurs modèles de substitution, exploitation du meilleur modèle pour une optimisation géométrique sous contraintes, et déploiement d’une application web interactive rendant l’ensemble accessible et démontrable.

Au-delà des résultats numériques, ce projet illustre une démarche méthodologique rigoureuse : l’échantillonnage naïf des données et le choix hâtif d’un modèle non-linéaire ont d’abord conduit à des performances médiocres ($R^2 \approx 0.66$), avant qu’une analyse de la structure physique du problème (échantillonnage log-uniforme, transformation log-log) ne permette d’atteindre une précision parfaite. Cette progression souligne un principe central en modélisation appliquée : comprendre la physique sous-jacente d’un problème permet souvent de choisir une représentation des données bien plus efficace qu’une approche générique de type « boîte noire ».

Ce travail constitue une première brique méthodologique, appelée à être étendue à des cas géométriquement et physiquement plus riches, où l’apport du Machine Learning face à des simulations coûteuses pourra être pleinement démontré.

6 Perspectives

- Étendre le solveur à une géométrie plus complexe (profilé en U), sans solution analytique fermée, pour évaluer le modèle sur un cas véritablement non-linéaire ;
- Tester le gain de temps de calcul sur une simulation FEM 2D/3D réellement coûteuse ;
- Explorer des architectures de deep learning (réseaux de neurones, physics-informed neural networks) sur des cas où la structure physique n’est pas connue *a priori*.